

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В.ЛОМОНОСОВА»

ФИЗИЧЕСКИЙ ФАКУЛЬТЕТ

КАФЕДРА МАТЕМАТИЧЕСКОГО МОДЕЛИРОВАНИЯ И ИНФОРМАТИКИ

Нейросетевой синтез текстур с трендами

Выполнил студент

435 группы:

Будакян Я. С.

Научный руководитель:

к.т.н., доц. Грачев Е. А.

Москва

2017

1 Введение

Задача состоит в синтезе изображений среды, которые будут содержать в себе тренд, т.е. изменение некоторой статистической характеристики. Такими трендами могут быть, например, изменение интенсивности появления частиц среды вдоль изображения, или изменение пористости среды.




Рис. 1: Пример текстуры с трендом интенсивности частиц

2 Математическая постановка

С математической точки зрения, задача сводится к синтезу случайного изображения X' (и построению соответствующей процедуры синтеза), принадлежащему распределению, близкому к желаемому:

$$P_{X'} \approx P_X,$$

где P_X - распределение изображений с трендами, удовлетворяющих следующим ограничениям (для упрощения задачи):

- Это монохромные изображения 256 x 256 пикселей
- Изменяющимся свойством является интенсивность появления частиц λ
- Тренд является линейным и направлен вдоль оси x: $\lambda = \lambda_0 + kx$

Распределение P_X задается обучающей выборкой.

3 Существующие подходы к решению задачи

Есть несколько подходов к решению задач подобного рода:

- 'Классический' статистический подход
- Базовый нейросетевой подход
- Генеративные состязательные сети (GAN)

3.1 'Классический' статистический подход

- Вводится параметризованное семейство распределений вероятности $P_\theta(x)$
- Параметры θ находятся из обучающей выборки:

$$\mathcal{L}_\theta(D) = \prod_{x \in D} P_\theta(x)$$

$$\theta^* = \arg \max_{\theta} \mathcal{L}_\theta(D)$$

- Генерируется семпл из P_{θ^*}

Этот подход приводит к проблемам:

- Пространство параметров θ может быть огромной размерности
- Известной параметрической модели распределения может вообще не существовать

Простой пример - синтез человеческих лиц: с помощью классического подхода эта задача не была решена с хорошим качеством.

3.2 Базовый нейросетевой подход

- Вводится параметризованное семейство распределений вероятности $P_\theta(x)$
 - Вводятся скрытые переменные V и функция(нейросеть) для получения x из V (фактически, классификация, развернутая в другую сторону)
- Определяются параметры распределения (т.е. обучение нейросети)
- Генерируются семплы из P_{θ^*}

Этот подход возможен, однако на практике трудноосуществим.

3.3 GAN - генеративные состязательные сети

Вернемся к изначальной задаче: найти процедуру генерирования X' так, чтобы $P_{X'} \approx P_X$. Переформулируем:

$$\rho(P_{X'}, P_X) \longrightarrow \min_{P_{X'}}$$

Введем некоторые скрытые переменные с фиксированным распределением, например

$$V \sim U^n[-1, 1],$$

и параметризованную процедуру генерации:

$$X' = g_\theta(V)$$

Переформулируем:

$$\rho(P_{X'}, P_X) \longrightarrow \min_{P_{X'}}$$

$$\rho(g_\theta(V), P_X) \longrightarrow \min_{g_\theta(V)}$$

$$\rho(g_\theta(V), P_X) \longrightarrow \min_{\theta}$$

Остается вопрос: что использовать в качестве метрики похожести двух распределений ρ , где одно из распределений задано обучающей выборкой. В качестве метрики статистической похожести можно использовать loss-функцию обученного классификатора:

$$\rho(P_{X'}, P_X) \longrightarrow \min \Leftrightarrow \mathcal{L} \longrightarrow \max,$$

где \mathcal{L} - функция потерь обученного классификатора. Соответственно, можно ввести две нейросети:

- $d_\zeta(x)$ - классификатор для измерения расстояния, **дискриминатор**
- $g_\theta(x)$ - сеть, трансформирующая V в X' , **генератор**

Введем loss-функцию дискриминатора(например, кросс-энтропия):

$$\begin{aligned} L(X, X') &= \frac{1}{2} \mathbb{E}_{x \sim X} l(d_\zeta(x), 1) + \frac{1}{2} \mathbb{E}_{x' \sim X'} l(d_\zeta(x'), 0) = \\ &= -\frac{1}{2} (\mathbb{E}_{x \sim X} \log d_\zeta(x) + \mathbb{E}_{x' \sim X'} \log(1 - d_\zeta(x'))) = \\ &= -\frac{1}{2} (\mathbb{E}_{x \sim X} \log d_\zeta(x) + \mathbb{E}_{v \sim V} \log(1 - d_\zeta(g_\theta(v)))) = \\ &= L(\zeta, \theta) \end{aligned}$$

Loss-функция обученного классификатора:

$$L^*(\theta) = \min_{\zeta} L(\zeta, \theta)$$

Соответственно,

$$\begin{aligned} \min_{\zeta} L(\zeta, \theta) &\longrightarrow \max_{\theta} \\ \theta^* &= \arg \max_{\theta} \left[\min_{\zeta} L(\zeta, \theta) \right] \end{aligned}$$

Определим оптимальный дискриминатор:

$$\begin{aligned} d_{\theta}^* &= d_{\zeta^*(\theta)} \\ \zeta^*(\theta) &= \arg \min_{\zeta} L(\zeta, \theta) \end{aligned}$$

4 Обучение GAN

Итак, задача обучения GAN свелась к нахождению

$$\theta^* = \arg \max_{\theta} \left[\min_{\zeta} L(\zeta, \theta) \right]$$

Решить ее можно, например, методом стохастического градиентного спуска:

$$\Delta\theta \sim \nabla L(\zeta^*(\theta), \theta)$$

Для малых изменений $\Delta\theta$:

$$\nabla L(\zeta^*(\theta), \theta) \approx \nabla L(\zeta^*(\theta), \theta + \Delta\theta)$$

В итоге, процесс обучения принимает следующий вид:

- Обучаем дискриминатор при 'замороженном' генераторе
- Обучаем генератор при 'замороженном' дискриминаторе
- Повторяем много раз




Рис. 2: Схематическое изображение процесса обучения GAN

5 pix2pix GAN

Для решения задачи было попробовано применить модификацию GAN-сети по названием "pix2pix GAN". Для нее функционал потерь выглядит следующим образом:

$$\mathcal{L}(G, D) = \mathcal{L}_{adv}(G, D) + \eta \mathbb{E}_{s_1, s_2, r \sim p_{data}(s_1, s_2, r)} (\| r - G(s_1, s_2) \|_1)$$

$$\begin{aligned} \mathcal{L}_{adv}(G, D) = & \mathbb{E}_{s_1, s_2, r \sim p_{data}(s_1, s_2, r)} \log D(s_1, s_2, r) + \\ & + \mathbb{E}_{s_1, s_2 \sim p_{data}(s_1, s_2)} \log(1 - D(s_1, s_2, G(s_1, s_2))) \end{aligned}$$

где G , D - генератор и дискриминатор, (s_1, s_2, r) - тройка изображений (интенсивность слева, справа и реальное изображение с трендом), $\mathbb{E}_{s_1, s_2, r \sim p_{data}(s_1, s_2, r)}$ - мат. ожидание логарифмического правдоподобия того, что тройка изображений (s_1, s_2, r) принадлежит вероятностному распределению реальных троек $p_{data}(s_1, s_2, r)$, а $p_{data}(s_1, s_2)$ соответствует распределению реальных изображений s_1, s_2 .




Рис. 3: Вход и желаемый выход нейросети

6 Критерий качества

После обучения генератора, необходимо проверить, что сгенерированные им изображения действительно имеют искомые характеристики. Для этого нужно ввести специальную метрику, которая будет учитывать наличие в изображении тренда интенсивности частиц. Было решено использовать среднюю плотность черных пикселей в некотором окне, и проходить этим окном по изображению (Рис. 4):

$$\xi_k = \frac{1}{Hw} \sum_{i=k}^{k+w} \sum_{j=0}^H \left| \frac{x(i, j) - 255}{255} \right|,$$
$$k = \overline{1, W - w + 1}$$




Рис. 4: Прохождение окном, W , H - размеры изображения, w - ширина окна

Построив график $\xi(k)$ можно увидеть, как меняется плотность пикселей и прослеживается ли тренд. В качестве метрики можно взять среднеквадратичную ошибку:

$$\xi = \frac{1}{W - w} \sum_{k=1}^{W-w+1} (\xi_k - \xi_{0k})^2,$$

где ξ_{0k} - ξ_k , усредненное по примерам из обучающей выборки.

7 Результаты

Было проведено обучение нейросети описанной архитектуры при различных гиперпараметрах. Обучающей выборкой был массив из 3500 троек изображений. Примеры сгенерированных текстур приведены на (Рис. 5). Была подсчитана введенная метрика для сгенерированных наборов текстур. Графики плотности черных пикселей в зависимости от сдвига окна, квадратичного отклонения от тренда и сами значения метрики приведены на (Рис. 6, 7, 8, 9) и в (Таб. 1, 2)




Рис. 5: Примеры сгенерированных текстур




Рис. 6: Плотность черных пикселей в окне в зависимости от сдвига окна

Сеть	Метрика
nf8	0.00825
nf32	0.00549
nf32-woUnet	0.00688

Таблица 1: Значения введенной метрики для разных сетей




Рис. 7: Плотность черных пикселей в окне в зависимости от сдвига окна

8 Заключение

Полученные результаты показывают, что в принципе нейросеть способна уловить тренд и воспроизвести его, однако на данный момент качество генерации относительно невысоко. Необходимо провести дальнейшее исследование оптимальных гиперпараметров, и, возможно, увеличить объем обучающей выборки. Также можно провести аналогичные эксперименты с другими архитектурами генераторов.

Сеть	Метрика
nf16	0.00606
nf16-woUnet	0.00881
nf16-3x3-woUnet	0.01034

Таблица 2: Значения введенной метрики для разных сетей




Рис. 8: Квадратичное отклонение от тренда для разных сетей



Рис. 9: Квадратичное отклонение от тренда для разных сетей