

Нейросетевой синтез текстур с трендами

Будалян Я. С.

Москва, 2017 г.

Введение

Целью работы является попытка применения нейросетевых подходов для синтеза текстур с протяженными корреляциями, то есть изменением некоторой статистической характеристики вдоль одного из направлений (трендом). Из работ[1, 2] видно, что у базовых нейросетевых генеративных моделей есть проблемы в этой области.

Введение

Для упрощения задачи, в работе рассматривается множество изображений с трендами, удовлетворяющее следующим ограничениям:

- Это монохромные изображения 256×256 пикселей
- Изменяющимся свойством является интенсивность появления частиц λ
- Тренд является линейным и направлен вдоль оси изображения z_1 : $\lambda = \lambda_{init} + kz_1$
- По оси z_2 остается равномерное распределение частиц

Введение




Рис.: Пример изображения с трендом, фиксируемого двумя изображениями

Введение

Математически задача синтеза текстуры с трендом описывается с помощью вероятностной постановки задачи обучения:

- Рассматривается многомерное пространство X , содержащее множество всех изображений x : $X = \{x\}$
- Есть обучающая выборка, состоящая из текстур с трендами $D = \{x_i\}$
- Считается, что D задает в X вероятностное распределение $P_X : X \rightarrow [0, 1]$

Введение

Таким образом задача синтеза текстуры из нужного множества сводится к синтезу случайного изображения x' из распределения, близкого к задаваемому обучающей выборкой:

$$P_{X'} \approx P_X, \quad x' \sim X'$$

GAN

Генеративные состязательные сети были придуманы в 2014 году и достигли больших успехов в задачах синтеза объектов из сложных распределений.

- Переформулируем: $P_{X'} \approx P_X \Leftrightarrow \rho(P_{X'}, P_X) \longrightarrow \min_{P_{X'}}$
- $X' = g_\theta(\cdot) \Rightarrow \rho(g_\theta(\cdot), P_X) \longrightarrow \min_\theta$
- В качестве ρ можно использовать функцию потерь обученного классификатора

GAN

Вводятся две нейросети:


- $d_{\zeta}(x)$ - классификатор для измерения расстояния, **дискриминатор**
- $g_{\theta}(x)$ - сеть, трансформирующая шум в элементы множества X' , **генератор**

Суть использования двух сетей состоит в том, что они обучаются совместно, конкурируя друг с другом.

GAN

Процесс обучения сети типа GAN принимает следующий вид:

- Обучаем дискриминатор при фиксированном генераторе
- Обучаем генератор при фиксированном дискриминаторе
- Повторяем до сходимости параметров обеих моделей



Оценка качества синтеза

Вводится специальная метрика, которая будет учитывать наличие в изображении тренда интенсивности частиц. Рассмотрим среднюю плотность черных пикселей в некотором окне ξ_k , и пройдем этим окном по изображению.

$$\xi_k = \frac{1}{Hw} \sum_{i=k}^{k+w} \sum_{j=0}^H \left| \frac{x(i,j) - 255}{255} \right|,$$
$$k = \overline{1, W - w}$$

Оценка качества синтеза

Построив график $\xi(k)$, можно увидеть, как меняется плотность черных пикселей и прослеживается ли тренд.




Рис.: Прохождение окном, W , H - размеры изображения, w - ширина окна.

Оценка качества синтеза

В качестве метрики можно взять среднеквадратичную ошибку:

$$\xi = \frac{K}{W - w} \sum_{k=1}^{W-w} (\xi_k - \xi_{0k})^2,$$

где ξ_{0k} - это ξ_k , усредненное по изображениям, содержащим истинный тренд, а K - нормировочный множитель, вводимый для того, чтобы метрики сетей, обученных на разных выборках можно было сравнивать между собой.

Результаты






















Вход 1	Вход 2	Тренд	Сеть nf8	nf16	nf16woU	nf32
						
						
						

Таблица: Примеры синтеза (Выборка 1)

Результаты




Рис.: Аппроксимация тренда различными сетями (Выборка 1)

Результаты

Сеть	Число фильтров на 1-ом слое	Метрика
nf16woU	16	0.24048
nf8	8	0.22511
nf16	16	0.18844
nf32	32	0.14589

Таблица: Значения метрики для разных сетей (меньше - лучше)

Результаты






















Вход 1	Вход 2	Тренд	Сеть nf32e5	nf64e1	nf64e5	nf64e10
						
						
						

Таблица: Примеры синтеза (Выборка 2)

Результаты



Рис.: Аппроксимация тренда различными сетями (Выборка 2)

Результаты

Сеть	Число фильтров на 1-ом слое	Метрика
nf64e10	64	0.11168
nf64e5	64	0.06501
nf32e5	32	0.04827
nf64e1	64	0.01393

Таблица: Значения метрики для разных сетей (меньше - лучше)

Выводы

- Исследовано применение архитектуры GAN для синтеза текстур с трендами
- Получены результаты синтеза при нескольких наборах гиперпараметров сети на нескольких выборках
- Проведено измерение качества генерации для каждого из наборов, используя введенную метрику

Результаты показывают на возможность применения GAN для синтеза текстур с трендами.

Спасибо за внимание!